

# 大型架构及配置技术

**NSD ARCHITECTURE** 

**DAY05** 

# 内容

上午	09:00 ~ 09:30	作业讲解和回顾
	09:30 ~ 10:20	大数据
	10:30 ~ 11:20	Hadoop
	11:30 ~ 12:00	
下午	14:00 ~ 14:50	Hadoop安装与配置
	15:00 ~ 15:50	
	16:10 ~ 17:10	HDFS
	17:20 ~ 18:00	总结和答疑



#### 大数据

 大数据介绍
 大数据的由来

 什么是大数据

 大数据特性

 大数据与Hadoop

大数据



# 大数据介绍



### 大数据的由来

#### 大数据

随着计算机技术的发展,互联网的普及,信息的积累已经到了一个非常庞大的地步,信息的增长也在不断的加快,随着互联网、物联网建设的加快,信息更是爆炸是增长,收集、检索、统计这些信息越发困难,必须使用新的技术来解决这些问题



#### 什么是大数据

- 大数据的定义
  - 大数据指无法在一定时间范围内用常规软件工具进行捕捉、管理和处理的数据集合,需要新处理模式才能具有更强的决策力、洞察发现力和流程优化能力的海量、高增长率和多样化的信息资产
  - 是指从各种各样类型的数据中, 快速获得有价值的信息





### 什么是大数据(续1)

- 大数据能做什么
  - 企业组织利用相关数据分析帮助他们降低成本、提高 效率、开发新产品、做出更明智的业务决策等
  - 把数据集合并后进行分析得出的信息和数据关系性,用来察觉商业趋势、判定研究质量、避免疾病扩散、 打击犯罪或测定即时交通路况等
  - 大规模并行处理数据库,数据挖掘电网,分布式文件系统或数据库,云计算平和可扩展的存储系统等



## 大数据特性







### 大数据特性(续1)

- 大数据的5V特性是什么?
  - (V)olume (大体量)
    可从数百TB到数十数百PB、甚至EB的规模
  - (V)ariety(多样性) 大数据包括各种格式和形态的数据
  - (V)elocity(时效性) 很多大数据需要在一定的时间限度下得到及时处理
  - (V)eracity(准确性)

    处理的结果要保证一定的准确性
  - (V)alue(大价值)

大数据包含很多深度的价值,大数据分析挖掘和利用将带来巨大的商业价值





# 大数据与Hadoop

- Hadoop是什么
  - Hadoop是一种分析和处理海量数据的软件平台
  - Hadoop是一款开源软件,使用JAVA开发
  - Hadoop可以提供一个分布式基础架构

- Hadoop特点
  - 高可靠性、高扩展性、高效性、高容错性、低成本



#### Hadoop

Hadoop历史起源 Hadoop起源 Hadoop组件 Hadoop常用组件 Hadoop核心组件 Hadoop Hadoop生态系统 HDFS结构 HDFS角色及概念 MapReduce结构 MapReduce结构及概念 Yarn结构 Yarn角色及概念



# Hadoop历史起源



## Hadoop起源

- 2003年开始Google陆续发表了3篇论文
  - GFS , MapReduce , BigTable
- GFS
  - GFS是一个可扩展的分布式文件系统,用于大型的、分布式 的、对大量数据进行访问的应用
  - 可以运行于廉价的普通硬件上,提供容错功能
- MapReduce
  - MapReduce是针对分布式并行计算的一套编程模型,由
     Map和Reduce组成,Map是映射,把指令分发到多个worker上,Reduce是规约,把worker计算出的结果合并





## Hadoop起源(续1)

- BigTable
  - BigTable是存储结构化数据
  - BigTable建立在GFS , Scheduler , Lock Service和 MapReduce之上
  - 每个Table都是一个多维的稀疏图





## Hadoop起源(续2)

- GFS、MapReduce和BigTable三大技术被称为 Google的三驾马车,虽然没有公布源码,但发布了 这三个产品的详细设计论
- Yahoo资助的Hadoop,是按照这三篇论文的开源 Java实现的,但在性能上Hadoop比Google要差很多
  - GFS - -> HDFS
  - MapReduce– > MapReduce
  - BigTable - -> Hbase





# Hadoop组件



## Hadoop常用组件

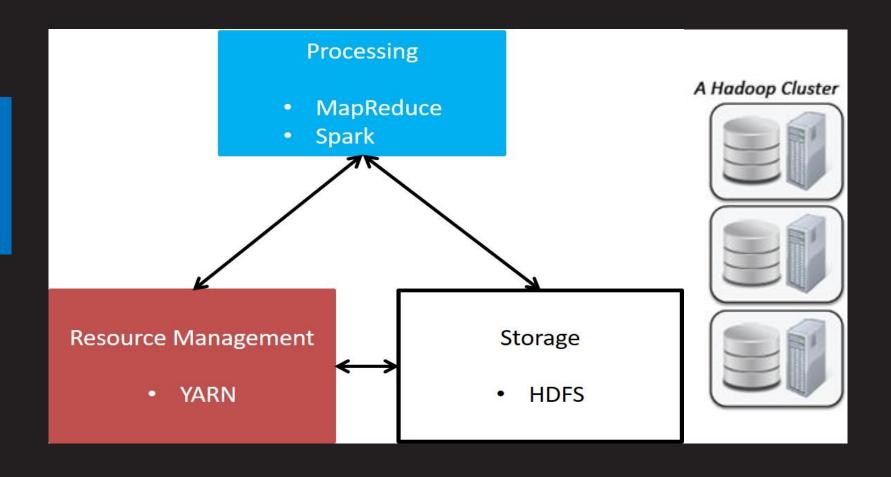
- HDFS: Hadoop分布式文件系统(核心组件)
- MapReduce:分布式计算框架(核心组件)
- Yarn:集群资源管理系统(核心组件)
- Zookeeper:分布式协作服务
- Hbase:分布式列存数据库
- Hive:基于Hadoop的数据仓库
- Sqoop:数据同步工具
- Pig:基于Hadoop的数据流系统
- Mahout:数据挖掘算法库







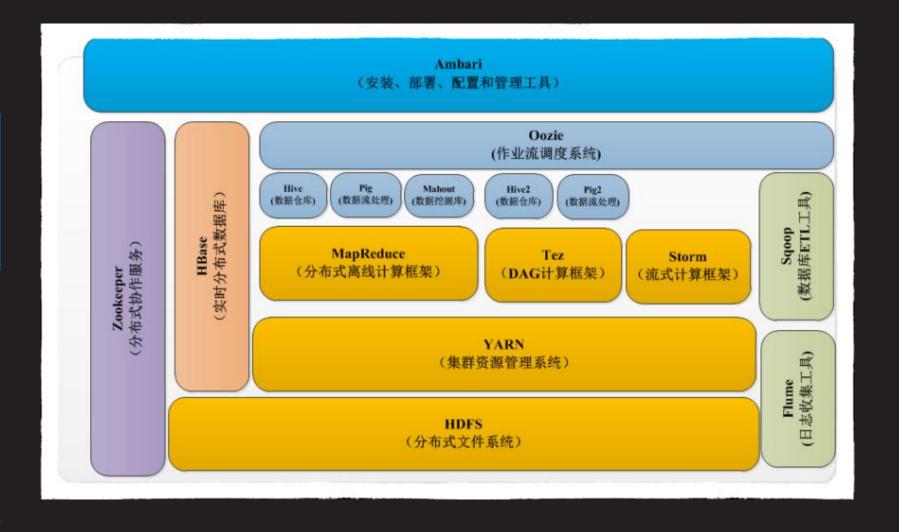
# Hadoop核心组件





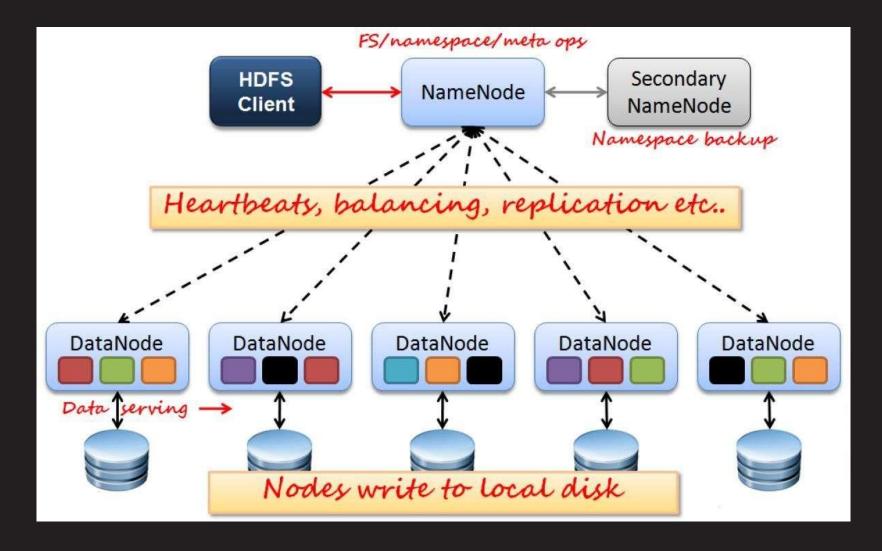


# Hadoop生态系统





# HDFS结构





### HDFS角色及概念

Hadoop体系中数据存储管理的基础,是一个高度容错的系统,用于在低成本的通用硬件上运行

- 角色和概念
  - Client
  - Namenode
  - Secondarynode
  - Datanode





## HDFS角色及概念(续1)

- NameNode
  - Master节点,管理HDFS的名称空间和数据块映射信息,配置副本策略,处理所有客户端请求

- Secondary NameNode
  - 定期合并fsimage 和fsedits , 推送给NameNode
  - 紧急情况下,可辅助恢复NameNode

• 但Secondary NameNode并非NameNode的热备





### HDFS角色及概念(续2)

- DataNode
  - 数据存储节点,存储实际的数据
  - 汇报存储信息给NameNode

#### Client

- 切分文件
- 访问HDFS
- 与NameNode交互,获取文件位置信息
- 与DataNode交互,读取和写入数据

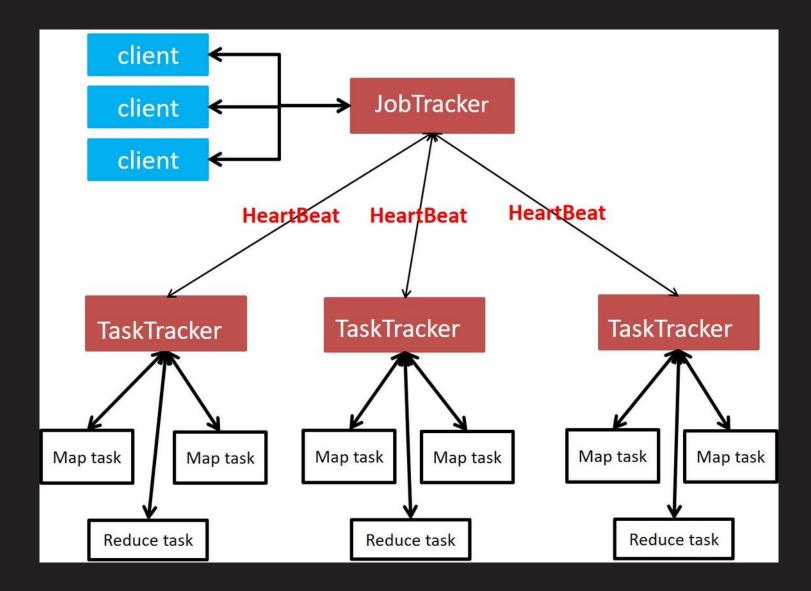


## HDFS角色及概念(续3)

- Block
  - 每块缺省64MB大小
  - 每块可以多个副本



# MapReduce结构







# MapReduce角色及概念

源自于Google的MapReduce论文, JAVA实现的分布式计算框架

- 角色和概念
  - JobTracker
  - TaskTracker
  - Map Task
  - Reducer Task





# MapReduce角色及概念(续1)

- JobTracker
  - Master节点只有一个
  - 管理所有作业/任务的监控、错误处理等
  - 将任务分解成一系列任务,并分派给TaskTracker

- TaskTracker
  - Slave节点,一般是多台
  - 运行Map Task和Reduce Task
  - 并与JobTracker交互, 汇报任务状态



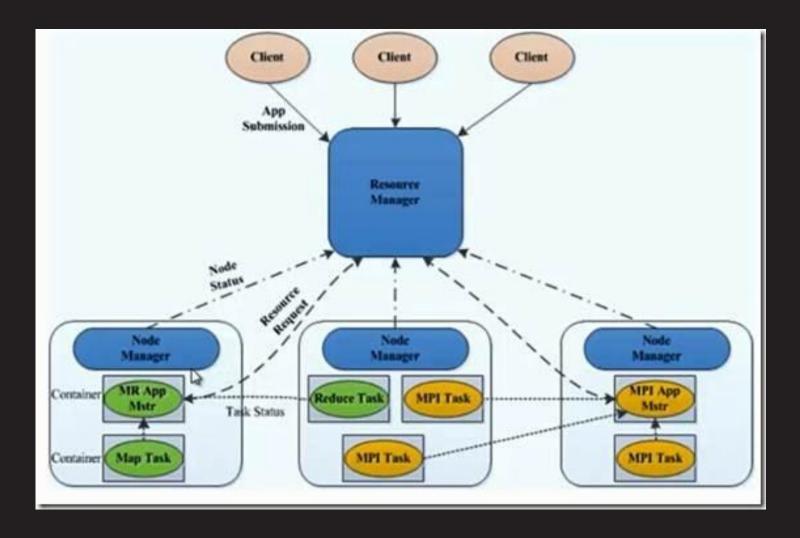


## MapReduce角色及概念(续2)

- · Map Task:解析每条数据记录,传递给用户编写的 map()并执行,将输出结果写入本地磁盘
  - 如果为map-only作业,直接写入HDFS
- Reducer Task: 从Map Task的执行结果中,远程读取输入数据,对数据进行排序,将数据按照分组传递给用户编写的reduce函数执行



# Yarn结构







## Yarn角色及概念(续1)

• Yarn是Hadoop的一个通用的资源管理系统

- Yarn角色
  - Resourcemanager
  - Nodemanager
  - ApplicationMaster
  - Container
  - Client



## Yarn角色及概念(续2)

- ResourceManager
  - 处理客户端请求
  - 启动/监控ApplicationMaster
  - 监控NodeManager
  - 资源分配与调度
- NodeManager
  - 单个节点上的资源管理
  - 处理来自ResourceManager的命令
  - 处理来自ApplicationMaster的命令





## Yarn角色及概念(续3)

- Container
  - 对任务运行行环境的抽象,封装了CPU、内存等
  - 多维资源以及环境变量、启动命令等任务运行相关的信息资源分配与调度
- ApplicationMaster
  - 数据切分
  - 为应用程序申请资源,并分配给内部任务
  - 任务监控与容错





## Yarn角色及概念(续4)

- Client
  - 用户与Yarn交互的客户端程序
  - 提交应用程序、监控应用程序状态, 杀死应用程序等





### Yarn角色及概念(续5)

- Yarn的核心思想
- 将JobTracker和TaskTacker进行分离,它由下面几大 构成组件
  - ResourceManager一个全局的资源管理器
  - NodeManager每个节点(RM)代理
  - ApplicationMaster表示每个应用
  - 每一个ApplicationMaster有多个Container在 NodeManager上运行



#### Hadoop安装与配置

Hadoop介绍

Hadoop模式

单机模式

伪分布式

Hadoop配置文件及格式

Hadoop安装与配置



# Hadoop介绍

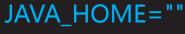
### Hadoop模式

- Hadoop的部署模式有三种
  - 单机
  - 伪分布式
  - 完全分布式



#### 单机模式

- Hadoop的单机模式安装非常简单
  - 获取软件 http://hadoop.apache.org
  - 安装配置Java环境,安装jps工具 安装Openjdk和Openjdk-devel
  - 设置环境变量,启动运行
  - hadoop-env.sh







### 单机模式(续1)

- Hadoop的单机模式安装很简单,只需配置好环境变量即 可运行,这个模式一般用来学习和测试Hadoop的功能
  - 测试 --- 统计词频

```
# cd /usr/local/hadoop
# mkdir input
# cp *.txt input/
# ./bin/hadoop jar ./share/hadoop/mapreduce/hadoop-mapreduce-
examples-2.7.3.jar wordcount input output
```





# 案例1:安装Hadoop

- 1. 单机模式安装Hadoop
- 2. 安装JAVA环境
- 3. 设置环境变量,启动运行



### 伪分布式

- 伪分布式

  - 伪分布式的配置和完全分布式配置类似





# Hadoop配置文件及格式

- 文件格式
  - Hadoop-env.sh

```
JAVA_HOME
HADOOP_CONF_DIR
```

- xml文件配置格式



#### **HDFS**

HDFS分布式文件系统

完全分布式

搭建完全分布式

课程知识点总结

**HDFS** 



# HDFS分布式文件系统

# 完全分布式

#### • 系统规划

主机	角色	软件
192.168.1.10 Nn01	NameNode SecondaryNameNode	HDFS
192.168.1.11 Node1	DataNode	HDFS
192.168.1.12 Node2	DataNode	HDFS
192.168.1.13 node3	DataNode	HDFS



### 搭建完全分布式

- 基础环境准备
  - 新开启3台虚拟机
  - 禁用 selinuxSELINUX=disabled
  - 禁用 firewalld# systemctl stop firewalld# systemctl mask firewalld
  - 安装 java-1.8.0-openjdk-devel

# yum install -y java-1.8.0-openjdk-devel





# 搭建完全分布式(续1)

- 基础环境准备
  - 在3台机器上配置/etc/hosts
  - 注意:所有主机都能ping通namenode的主机名,namenode能ping通所有节点
  - java -version 验证java安装
  - jps 验证角色





# 搭建完全分布式(续2)

- 配置SSH信任关系(NameNode)
  - 注意:不能出现要求输入yes的情况,每台机器都要能 <u>登录成功,包括本机!!!</u>
  - ssh\_configStrictHostKeyChecking no

```
# ssh-keygen -b 2048 -t rsa -N " -f key
# ssh-copy-id -i ./key.pub root@ip.xx.xx.xx
```





# 搭建完全分布式(续3)

HDFS完全分布式系统配置

- 环境配置文件: hadoop-env.sh

- 核心配置文件: core-site.xml

- HDFS配置文件: hdfs-site.xml

- 节点配置文件:slaves





# 搭建完全分布式(续4)

- 环境配置文件hadoop-env.sh
  - OpenJDK的安装目录: JAVA\_HOME
  - Hadoop配置文件的存放目录: HADOOP\_CONF\_DIR





# 搭建完全分布式(续5)

- 核心配置文件 core-site.xml
  - fs.defaultFS:文件系统配置参数
  - hadoop.tmp.dir:数据目录配置参数





# 搭建完全分布式(续6)

- HDFS配置文件hdfs-site.xml
  - Namenode: 地址声明 dfs.namenode.http-address
  - Secondarynamenode: 地址声明 dfs.namenode.secondary.http-address
  - 文件冗余份数 dfs.replication





### 搭建完全分布式(续7)

HDFS配置文件hdfs-site.xml

```
cproperty>
    <name>dfs.namenode.http-address</name>
    <value>nn01:50070</value>
  </property>
  cproperty>
    <name>dfs.namenode.secondary.http-
address</name>
    <value>nn01:50090</value>
  </property>
  cproperty>
    <name>dfs.replication</name>
    <value>2</value>
  </property>
```





# 搭建完全分布式(续8)

- 节点配置文件slaves
  - 只写DataNode节点的主机名称

node1

node2

node3

- 同步配置
- Hadoop所有节点的配置参数完全一样,在一台配置好后,把配置文件同步到其它所有主机上





# 搭建完全分布式(续9)

- · HDFS完全分布式配置
  - 在所有机器上创建/var/hadoop文件夹# mkdir /var/hadoop
  - 在namenode上执行格式化操作# ./bin/hdfs namenode -format
  - 启动集群
    - # ./sbin/start-dfs.sh





# 搭建完全分布式(续10)

- JPS验证角色
  - NameNode验证

[root@nn01 hadoop]# jps 29826 SecondaryNameNode 31237 Jps 29643 NameNode

– DataNode验证

[root@node1 ~]# jps 24472 Jps 24027 DataNode





### 搭建完全分布式(续11)

- 节点验证
  - NameNode上
  - bin/hdfs dfsadmin -report

[root@nn01 hadoop]# bin/hdfs dfsadmin -report Configured Capacity: 51505004544 (47.97 GB)

DFS Used: 733184 (716 KB)

...

Missing blocks: 0

Missing blocks (with replication factor 1): 0

-----

Live datanodes (3):





### 案例2:安装配置Hadoop

- 1. 另备三台虚拟机,安装Hadoop
- 2. 使所有节点能够ping通,配置SSH信任关系
- 3. 节点验证



#### 课程知识点总结

- 大数据的5V特性
  - (V)olume (大体量)
  - (V)ariety(多样性)
  - (V)elocity(时效性)
  - (V)eracity(准确性)
  - (V)alue(大价值)





### 课程知识点总结(续1)

- Hadoop是用什么语言开发的
  - JAVA
- Hadoop的三大核心组件
  - Hdfs
  - MapReduce
  - Yarn





### 课程知识点总结(续2)

- Hadoop有几种部署模式
  - 单机
  - 伪分布式
  - 完全分布式
- 列举5种Hadoop的常见组件



#### 总结和答疑

同步数据出错

问题现象

故障分析及排除

总结和答疑



# 同步数据出错



#### 问题现象

• rsync同步数据不成功

bash: rsync: command not found

rsync: connection unexpectedly closed (0 bytes received so far)

[sender]

rsync error: remote command not found (code 127) at io.c(226)

[sender=3.1.2]





### 故障分析及排除

- 原因分析
  - 要同步数据的主机没有安装rsync
- 解决方案
  - 安装rsync

